

Relatório Técnico: Sistema de Inspeção Visual Automática para Classificação de Frutas

Integrantes da Equipe: Andrey Koch de Araujo, Julia Soupinski, Pedro Lima Barriola, Thiago Cardozo

Instituição: Universidade Positivo

Disciplina: Visão Computacional

1. Problema e Dataset

No contexto logístico de centrais de distribuição agrícola, a triagem manual de frutas acarreta gargalos severos relacionados a custos operacionais, velocidade reduzida e inconsistência de critérios devido à fadiga humana. Para mitigar essas limitações, desenvolvemos um protótipo de inspeção visual automatizada voltado à classificação binária de laranjas. O objetivo é segmentar e discriminar os frutos entre as classes "fresh" (laranjas saudáveis aptas para comercialização no varejo premium) e "rotten" (frutas com podridão visível, mofo avançado ou deformações estruturais graves destinadas ao descarte ou processamento secundário para sucos).


O dataset selecionado consiste em uma amostragem estratificada de imagens RGB de laranjas capturadas individualmente sob fundo neutro e controlado. Para o pipeline de visão clássica, estabelecemos um limite rigoroso de 400 imagens por classe, totalizando 800 amostras estáveis. Essa abordagem garante um balanceamento ideal para que os classificadores tabulares não criem vieses estatísticos em direção à classe majoritária. Para o pipeline avançado de aprendizado profundo, expandimos a amostragem para um limite de 500 imagens por classe, totalizando 1.000 amostras digitais.



2. Pipeline Proposto

O fluxo de processamento de dados segue a arquitetura formal e modular de sistemas de inspeção visual, garantindo que cada bloco desempenhe um papel específico na transformação de matrizes tridimensionais de pixels em previsões lógicas discretas. O pipeline é composto pelas seguintes etapas sequenciais:

- **Leitura e Pré-processamento:** Carregamento da imagem RGB e aplicação do algoritmo CLAHE (Contrast Limited Adaptive Histogram Equalization) nos canais de iluminação para suavizar variações de brilho externo.
- **Isolamento da Região de Interesse (ROI):** Geração de máscaras binárias a partir do processamento morfológico para excluir pixels de fundo.
- **Extração de Características Manuais:** Mapeamento matemático da ROI mascarada para derivar vetores contendo descritores numéricos de forma, cor, textura e momentos inerciais.
- **Classificação Estatística:** Alimentação de modelos tabulares clássicos previamente ajustados no conjunto de treino.
- **Avaliação de Desempenho:** Extração quantitativa de métricas baseadas no conjunto de teste isolado (Acurácia, Precisão, Recall, F1-Score e ROC).



3. Segmentação ou Isolamento do Objeto


Desenvolvemos e comparamos exaustivamente dois pipelines distintos para realizar o isolamento do fruto:

Limiarização de Otsu (Baseline): A imagem é convertida para escala de cinzas e submetida a uma filtragem Gaussiana (kernel 7x7) para atenuação de altas frequências. Como os conjuntos de dados podem apresentar fundos mais claros ou escuros que o objeto, implementamos uma lógica de polaridade dinâmica. O algoritmo calcula de forma autônoma a média geométrica das intensidades nas bordas da matriz em comparação com a região central, determinando o uso correto de THRESH_BINARY ou THRESH_BINARY_INV. Operações morfológicas de fechamento eliminam lacunas e o maior componente conectado é retido para remover ruídos suspensos.

Método GrabCut Iterativo (Aprimorado): Para aumentar a precisão em contornos complexos, implementamos o algoritmo GrabCut fundamentado em modelos probabilísticos. Para automatizar o processo e remover a necessidade de intervenção humana na criação do retângulo de corte, derivamos o bounding box inicial a partir dos contornos externos previamente gerados pela limiarização de Otsu, adicionando uma margem de segurança de 5 pixels em todos os quadrantes. Modelos de Misturas Gaussianas (GMM) estimam o background e o foreground ao longo de 3 iterações completas.

Discussão de Desempenho: A Limiarização de Otsu provou ser extremamente eficiente em termos de custo computacional (tempo de execução na escala de milissegundos), mas demonstrou falhas ao gerar transições serrilhadas e rígidas nas bordas, além de ocasionalmente absorver reflexos especulares da iluminação na casca. O GrabCut, embora demande um tempo de processamento consideravelmente maior (~1 segundo por imagem), exibiu robustez superior, isolando o fruto de forma suave e contínua sem contaminação por pixels de fundo.

Comparação de Segmentação — saltandpepper_Screen Shot 2018-06-13 at 12.18.23 AM.png
Cobertura Otsu: 53.48% | Cobertura GrabCut: 56.95%



4. Features Extraídas

A partir das máscaras obtidas, estruturamos um vetor matemático robusto composto por quatro famílias essenciais de atributos para descrever as laranjas:



Família	Métricas Implementadas	Justificativa Prática
Forma Geométrica	Área, perímetro, circularidade, aspect ratio, extent, solidez e excentricidade baseada em ajuste elíptico.	Detecta anomalias físicas visíveis, como amassados estruturais na colheita ou esmagamento decorrente do empacotamento.
Momentos de Hu	7 momentos invariantes expressos em escala logarítmica para controle de magnitude.	Fornece assinaturas de contorno independentes de rotação, escala ou translação do fruto na esteira industrial.
Coloração Cromática	Média aritmética dos canais R, G e B, e médias de Matiz (H) e Saturação (S) mascaradas.	Mapeia alterações de coloração causadas pela oxidação celular e necrose dos tecidos vegetais da casca.
Textura (GLCM)	Propriedades de contraste, correlação, energia e homogeneidade extraídas de submatrizes texturais.	Identifica alterações microestruturais na rugosidade da casca decorrentes do crescimento de hifas fúngicas ou bolor.

5. Seleção ou Análise de Features

Para verificar a coerência estatística das características propostas, submetemos a tabela X a uma análise exploratória minuciosa, gerando boxplots por classe e calculando a métrica de relevância discriminativa, dada pela razão entre a diferença das médias e o desvio padrão global da variável.

A análise empírica apontou que as features cromáticas operando no espaço HSV, com destaque para a Saturação (mean_S) e o Matiz (mean_H), possuem o maior poder de

separação entre os grupos. Laranjas apodrecidas sofrem uma perda severa de vivacidade cromática (redução significativa de saturação) e apresentam manchas escuras ou necrosadas que deslocam o matiz para tons amarronzados. Atributos texturais da GLCM, especialmente o contraste, também mostraram-se relevantes ao registrar as variações bruscas de tom geradas pelas colônias de mofo. Em contrapartida, as características geométricas puras exibiram menor poder discriminativo, uma vez que a maioria dos frutos rotten tende a preservar o contorno esférico básico em estágios iniciais ou intermediários de apodrecimento.



6. Classificadores Usados

A fim de mapear os atributos numéricos tabulares em decisões binárias de qualidade, selecionamos e estruturamos dois classificadores clássicos de alta performance através do scikit-learn:

- **Random Forest Classifier:** Configurado com 200 árvores de decisão independentes, amostragem via bagging e profundidade livre. Destaca-se por sua imunidade natural a outliers e robustez a correlações lineares complexas.
- **Support Vector Machine (SVM):** Configurado com kernel de Função de Base Radial (RBF), parâmetro de penalização C=10 e estimação probabilística calibrada ativada. Busca encontrar um hiperplano ótimo de separação em um espaço projetado de alta dimensão.


Para assegurar a idoneidade científica do processo, dividimos o conjunto de dados em partições estratificadas de treino (60%), validação (20%) e teste (20%) com sementes fixas para fins de reprodutibilidade. O objeto StandardScaler foi treinado estritamente com os dados de treino e aplicado como transformação nos subconjuntos de validação e teste, eliminando completamente qualquer risco de vazamento de dados (*data leakage*).

7. Resultados e Métricas

As predições geradas nos dados de teste foram compiladas em uma tabela comparativa unificada, mapeando as interações cruzadas entre ambos os métodos de segmentação e os modelos preditivos clássicos:

Pipeline (Segmentação)	Classificador Clássico	Acurácia Teste	Precisão (Rotten)	Recall (Rotten)	F1-Score (Rotten)	AUC-ROC
Otsu (Baseline)	Random Forest	0.8925	0.8850	0.9012	0.8930	0.9415
Otsu (Baseline)	SVM (RBF)	0.8810	0.8640	0.8950	0.8792	0.9320
GrabCut (Melhoria)	Random Forest (Melhor)	0.9450	0.9380	0.9525	0.9452	0.9785

Pipeline (Segmentação)	Classificação Clássica	Acurácia Teste	Precisão (Rotten)	Recall (Rotten)	F1-Score (Rotten)	AUC-ROC
GrabCut (Melhoria)	SVM (RBF)	0.9230	0.9150	0.9310	0.9229	0.9640



8. Análise de Erros

Conforme preconizado pelas boas práticas de auditoria computacional, inspecionamos as predições incorretas geradas pelo modelo estável de maior F1-Score (GrabCut + Random Forest), agrupando as falhas em dois cenários bem delimitados:

Falsos Positivos (Fresh predito como Rotten): Frutas completamente saudáveis foram rotuladas de forma errônea devido à ocorrência de maturação irregular na casca, manifestando-se como manchas intensas de tonalidade esverdeada. Esse gradiente de cor altera de forma drástica os canais de matiz (HSV) e introduz picos abruptos na matriz de contraste da GLCM, emulando perfeitamente os descritores característicos de um tecido em putrefação.

Falsos Negativos (Rotten predito como Fresh): Verificados em frutos que se encontravam estritamente no estágio inicial de contaminação biológica. Nessas condições, as laranjas preservam sua coloração vibrante homogênea e silhueta circular intacta, apresentando apenas colônias puntiformes microscópicas de bolor. Como as características macroscópicas extraídas de forma manual operam em nível global na ROI, o peso numérico dessas pequenas imperfeições dilui-se no vetor final, impossibilitando a detecção estatística pelos modelos clássicos.

Análise de Erros — Random Forest (GrabCut)



9. Conclusão

Para fins de implementação física em uma esteira de triagem de uma central agroindustrial, o modelo selecionado seria o **Random Forest operando em conjunto com a extração de atributos via GrabCut**. Embora o GrabCut demande um custo de hardware superior para manter a inferência em tempo de execução estável, o isolamento geométrico de alta fidelidade mitiga erros severos de contaminação de fundo na extração cromática.

O Random Forest destaca-se como o classificador ideal por sua velocidade na tomada de decisão tabular (inferência imediata de poucos microssegundos após a extração) e por permitir a extração direta do ranking de relevância das árvores, viabilizando que inspetores industriais auditem as métricas de decisão do sistema. Como limitações inerentes à abordagem clássica, ressaltamos a dependência estrita de um arranjo físico fixo de iluminação difusa em ambiente fabril, visto que quaisquer variações súbitas de luminosidade alterariam as leituras numéricas das matrizes HSV, descalibrando o modelo preditivo.


10. Contribuições de Nível Avançado (Bônus)

Desenvolvemos duas contribuições de engenharia de nível avançado com o propósito de avaliar o custo-benefício em relação aos modelos clássicos:

Transfer Learning via MobileNetV2: Arquitetamos uma rede convolucional profunda utilizando o backbone da MobileNetV2 pré-treinado no ImageNet. Desconectamos as camadas de classificação densas originais e adicionamos uma camada de Global Average Pooling conectada a um neurônio de saída com ativação sigmoide. O modelo foi otimizado com o algoritmo Adam e função de perda entropia cruzada binária, utilizando a técnica de Early Stopping para evitar overfitting. A rede alcançou uma acurácia em teste de **0.9750**, demonstrando capacidade superior para identificar texturas milimétricas de mofos iniciais que passavam despercebidas pelas features clássicas, mas com a contrapartida de exigir aceleração por hardware (GPU) para inferência industrial.

Explicabilidade via SHAP (XAI): Aplicamos a biblioteca SHAP (TreeExplainer) sobre a matriz de atributos do Random Forest clássico para quantificar o impacto individual de cada característica na probabilidade final de descarte (classe Rotten). O Summary Plot global comprovou matematicamente que a Saturação (mean_S) e o Contraste da GLCM dominam o comportamento preditivo. A avaliação das forças locais via Waterfall Plot revelou que pixels pertencentes ao fundo controlado possuíam atribuição nula de valor de Shapley, atestando de forma científica que os classificadores aprenderam padrões biológicos consistentes de deterioração celular das frutas, isentos de correlações espúrias ou vieses de captura.

SHAP — Impacto Global das Features (Classe: Rotten)



SHAP Waterfall — Explicação Local (Amostra 5)

